Ciencia de Datos: Un Enfoque Práctico en la Era del Big Data Hadoop: Caso Práctico 1

Sara Del Río García

Departamento de Ciencias de la Computación e Inteligencia Artificial, E.T.S. de Ingenierías Informática y de Telecomunicación, srio@decsai.ugr.es







Contenido

- Ejemplo: WordCount
- WordCount usando MapReduce
- Referencias

Contenido

- Ejemplo: WordCount
- WordCount usando MapReduce
- 3 Referencias

Ejemplo: WordCount

 Tenemos un fichero de gran tamaño que contiene secuencias de palabras



OBJETIVO:

Contar el número de veces que aparece cada palabra en el fichero

Contenido

- Ejemplo: WordCount
- WordCount usando MapReduce
- 3 Referencias

WordCount usando MapReduce

Pseudocódigo

Algorithm 1 map(key, value) // key: document ID; value: text of document:

```
1: for each word w in value do
```

2: EMIT (w, 1)

3: end for

Algorithm 2 reduce(key, value-list) // key: a word; value-list: a list of integers (theoretically// 1, but ... "combiners")

```
1: result \leftarrow 0
```

2: for each count v on value - list do


3: $result \leftarrow result + v$

4: end for

5: EMIT (key, result)

WordCount usando MapReduce

Walkthrough of WordCount example (but ... "combiners").



WordCount usando MapReduce

Main Class

```
package org.myorg;
import java.io.IOException;
import java.util.*;
import org.apache.hadoop.fs.Path;
import org.apache.hadoop.conf.*;
import org.apache.hadoop.io.*;
import org.apache.hadoop.mapred.*;
import org.apache.hadoop.util.*;
public class WordCount {
```

WordCount usando MapReduce

Mapper Class

```
public static class Map extends MapReduceBase
    implements Mapper<LongWritable, Text, Text, IntWritable>
private final static IntWritable one = new IntWritable(1);
private Text word = new Text();
public void map (LongWritable key, Text value,
    OutputCollector<Text, IntWritable> output, Reporter
    reporter) throws IOException {
  String line = value.toString();
  StringTokenizer tokenizer = new StringTokenizer(line);
  while (tokenizer.hasMoreTokens()) {
    word.set(tokenizer.nextToken()):
    output.collect(word, one);
```

WordCount usando MapReduce

Reducer Class

```
public static class Reduce extends MapReduceBase
implements Reducer<Text, IntWritable, Text, IntWritable>
{

public void reduce(Text key, Iterator<IntWritable> values,
    OutputCollector<Text, IntWritable> output, Reporter
    reporter) throws IOException {

int sum = 0;
    while (values.hasNext()) {
        sum += values.next().get();
    }
    output.collect(key, new IntWritable(sum));
}
```


WordCount usando MapReduce

Main method

```
public static void main(String[] args) throws Exception
JobConf conf = new JobConf (WordCount.class);
conf.setJobName("wordcount");
conf.setOutputKevClass(Text.class);
conf.setOutputValueClass(IntWritable.class);
conf.setMapperClass(Map.class);
conf.setCombinerClass(Reduce.class);
conf.setReducerClass(Reduce.class);
conf.setInputFormat(TextInputFormat.class);
conf.setOutputFormat(TextOutputFormat.class);
FileInputFormat.setInputPaths(conf, new Path(args[0]));
FileOutputFormat.setOutputPath(conf, new Path(args[1]));
JobClient.runJob(conf);
```

WordCount usando MapReduce

Walkthrough of WordCount example (with "combiners").



WordCount usando MapReduce

Uso:

Crear el directorio de entrada "/user/hadoop/wordcount/input" en HDFS:

hadoop fs -mkdir /user/hadoop/wordcount /user/hadoop/wordcount/input

Crear ficheros de texto de ejemplo y copiarlos al directorio creado previamente en HDFS:

echo "Hello World Bye World" > file0

echo "Hello Hadoop Goodbye Hadoop" > file1

hadoop fs -put file* /user/hadoop/wordcount/input

Sara Del Río 9 de Abril del 2016 13 / 19

WordCount usando MapReduce

- Uso:
 - Compilar "WordCount.java":

mkdir wordcount_classes

javac -cp /usr/lib/hadoop/*:/usr/lib/hadoop-mapreduce/* -d wordcount_classes WordCount.java

Orear el JAR:

jar -cvf wordcount.jar -C wordcount_classes/ .

Ejecutar la aplicación:

hadoop jar wordcount.jar org.myorg.WordCount /user/hadoop/wordcount/input /user/hadoop/wordcount/output

Sara Del Río 9 de Abril del 2016 14 / 19

WordCount usando MapReduce

- Uso:
 - Comprobar la salida:

hadoop fs -cat wordcount/output/part-00000

Obtendermos la siguiente salida:

Bye 1 Goodbye 1 Hadoop 2 Hello 2 World 2

Sara Del Río 9 de Abril del 2016 15 / 19

Contenido

- Ejemplo: WordCount
- WordCount usando MapReduce
- 3 Referencias

Sara Del Río 9 de Abril del 2016 16 / 19

Referencias

• Hadoop Tutorial - WordCount:

http://www.cloudera.com/documentation/other/tutorial/CDH5/Hadoop-Tutorial/ht_wordcount1.html

Sara Del Río 9 de Abril del 2016 17 / 19

Happy Hadooping!



Sara Del Río 9 de Abril del 2016 18 / 19

Ciencia de Datos: Un Enfoque Práctico en la Era del Big Data Hadoop: Caso Práctico 1

Sara Del Río García

Departamento de Ciencias de la Computación e Inteligencia Artificial, E.T.S. de Ingenierías Informática y de Telecomunicación, srio@decsai.ugr.es







Sara Del Río 9 de Abril del 2016 19/19